

Statistiques descriptives

I. Caractéristiques d'une série statistique

1) Série statistique

Voici les séries de notes obtenues par 3 élèves :

Jérôme : 4 ; 6 ; 18 ; 7 ; 17 ; 12 ; 12 ; 18

Bertrand : 13 ; 13 ; 12 ; 10 ; 12 ; 3 ; 14 ; 12 ; 14 ; 15

Julie : 15 ; 9 ; 14 ; 13 ; 10 ; 12 ; 12 ; 11 ; 10

2) Moyenne

Méthode : Calculer une moyenne

Calculer la moyenne pour chaque série de notes de Jérôme, de Bertrand et de Julie.

$$M(\text{Jérôme}) = (4 + 6 + 18 + 7 + 17 + 12 + 12 + 18) : 8 \approx 11,8$$

$$M(\text{Bertrand}) = (13 + 13 + 12 + 10 + 12 + 3 + 14 + 12 + 14 + 15) : 10 = 11,8$$

$$M(\text{Julie}) = (15 + 9 + 14 + 13 + 10 + 12 + 12 + 11 + 10) : 9 \approx 11,8$$

La moyenne est une caractéristique de position.

3) Médiane

Méthode : Calculer une médiane

Calculer la médiane pour chaque série de notes de Jérôme, de Bertrand et de Julie.

Pour déterminer les notes médianes, il faut **ordonner les séries**. La médiane partage l'effectif en deux.


On a représenté ci-dessous le nuage de points de la série.



$$m(\text{Jérôme}) = \frac{12 + 12}{2} = 12$$



$$m(\text{Bertrand}) = \frac{12 + 13}{2} = 12,5$$

**Définition :**

La **médiane** m est une valeur telle que la moitié au moins de l'effectif ait des valeurs inférieures ou égales à m , l'autre moitié des valeurs supérieures ou égales à m .

La médiane est une caractéristique de position.

4) Étendue**Définition :**

L'**étendue** d'une série statistique est la différence entre la plus grande valeur et la plus petite valeur de la série.

Méthode : Calculer une étendue

Calculer l'étendue pour chaque série de notes de Jérôme, de Bertrand et de Julie.

$$\begin{aligned}E(\text{Jérôme}) &= 18 - 4 = 14 \\E(\text{Bertrand}) &= 15 - 3 = 12 \\E(\text{Julie}) &= 15 - 9 = 6\end{aligned}$$

Dans la série de Bertrand, la valeur « 3 » est très éloignée des autres notes : c'est une **valeur aberrante**, qui gonfle fortement l'étendue. On verra plus loin que l'écart interquartile, lui, n'est pas sensible à ce type de valeur extrême.

L'étendue est une caractéristique de dispersion.

5) Quartiles, écart interquartile

Définitions :

Le **premier quartile** est la plus petite valeur de la série telle qu'au moins 25 % des valeurs de la série sont inférieures ou égales à cette valeur.

Le **troisième quartile** est la plus petite valeur de la série telle qu'au moins 75 % des valeurs de la série sont inférieures ou égales à cette valeur.

Définition :

L'**écart interquartile** d'une série statistique de premier quartile Q_1 et de troisième quartile Q_3 est égal à la différence $Q_3 - Q_1$.

Remarque :

L'écart interquartile d'une série mesure la dispersion autour de la médiane. Il contient au moins 50 % des valeurs de la série.

L'écart interquartile **n'est pas influencé** par les valeurs extrêmes de la série.

Méthode : Calculer les quartiles

Calculer les quartiles pour chaque série de notes de Jérôme, de Bertrand et de Julie.

Pour déterminer les quartiles, il faut **ordonner les séries**.

Le premier quartile est la donnée de la série se trouvant au **quart** de l'effectif.

Le troisième quartile est la donnée de la série se trouvant aux **trois-quarts** de l'effectif.

Jérôme (effectif 8)

4 6 7 12 12 17 18 18

$\frac{1}{4} \times 8 = 2$, le premier quartile est la **2^e donnée** de la série ordonnée.

$\frac{3}{4} \times 8 = 6$, le troisième quartile est la **6^e donnée** de la série ordonnée.

$$Q_1(\text{Jérôme}) = 6 \quad Q_3(\text{Jérôme}) = 17$$

L'écart interquartile est égal à $E_Q(\text{Jérôme}) = Q_3(\text{Jérôme}) - Q_1(\text{Jérôme}) = 17 - 6 = 11$.

Bertrand (effectif 10)

3 10 12 12 12 13 13 14 14 15

$\frac{1}{4} \times 10 = 2,5$, le premier quartile est la **3^e donnée** de la série ordonnée.

$\frac{3}{4} \times 10 = 7,5$, le troisième quartile est la **8^e donnée** de la série ordonnée.

$$Q_1(\text{Bertrand}) = 12 \quad Q_3(\text{Bertrand}) = 14$$

L'écart interquartile est égal à $E_Q(\text{Bertrand}) = Q_3(\text{Bertrand}) - Q_1(\text{Bertrand}) = 14 - 12 = 2$.

Julie (effectif 9)

9 10 10 11 12 12 13 14 15

$\frac{1}{4} \times 9 = 2,25$, le premier quartile est la **3^e donnée** de la série ordonnée.

$\frac{3}{4} \times 9 = 6,75$, le troisième quartile est la **7^e donnée** de la série ordonnée.

$$Q_1(\text{Julie}) = 10 \quad Q_3(\text{Julie}) = 13$$

L'écart interquartile est égal à $E_Q(\text{Julie}) = Q_3(\text{Julie}) - Q_1(\text{Julie}) = 13 - 10 = 3$.

6) Interprétations

Les quartiles sont des caractéristiques de position.

L'écart interquartile est une caractéristique de dispersion.

$M(\text{Jérôme}) = 11,8$	$m(\text{Jérôme}) = 12$	$E(\text{Jérôme}) = 14$
$M(\text{Bertrand}) = 11,8$	$m(\text{Bertrand}) = 12,5$	$E(\text{Bertrand}) = 12$
$M(\text{Julie}) \approx 11,8$	$m(\text{Julie}) = 12$	$E(\text{Julie}) = 6$
$Q_1(\text{Jérôme}) = 6$	$Q_3(\text{Jérôme}) = 17$	$E_Q(\text{Jérôme}) = 11$
$Q_1(\text{Bertrand}) = 12$	$Q_3(\text{Bertrand}) = 14$	$E_Q(\text{Bertrand}) = 2$
$Q_1(\text{Julie}) = 10$	$Q_3(\text{Julie}) = 13$	$E_Q(\text{Julie}) = 3$

Les moyennes sont environ égales et pourtant les notes ne se répartissent pas de la même manière autour de cette caractéristique de position. Les étendues de Jérôme (14) et de Bertrand (12) sont proches, mais leurs **écarts interquartiles** diffèrent beaucoup (11 contre 2) : l'étendue de Bertrand est en effet gonflée par la valeur aberrante 3, alors que l'écart interquartile n'en tient pas compte.

Dire que Jérôme a une **médiane** égale à 12 signifie que Jérôme a obtenu autant de notes au-dessus de 12 que de notes en-dessous de 12.

Dire que le **premier quartile** de Bertrand est égal à 12 signifie qu'au moins un quart des notes de Bertrand sont inférieures ou égales à 12.

Dire que le **troisième quartile** de Julie est égal à 13 signifie qu'au moins trois quarts des notes de Julie sont inférieures ou égales à 13.

L'**écart interquartile** de Jérôme est égal à 11 signifie qu'au moins 50 % des notes de Jérôme sont comprises entre 6 et 17 (les quartiles).

II. Cas de pondération d'une série statistique

1) Série statistique

Tailles des élèves de 2^{nde} 5 en cm :

174 – 160 – 161 – 166 – 177 – 172 – 157 – 175 – 162 – 169 – 160 – 165 – 170 – 152
– 168 – 156 – 163 – 167 – 169 – 158 – 164 – 151 – 162 – 166 – 156 – 165 – 179

2) Regroupement par classe



Regrouper cette série de tailles par classes de longueur 5 cm et calculer les **fréquences arrondies au centième** :

Tailles	$150 \leq t < 155$	$155 \leq t < 160$	$160 \leq t < 165$	$165 \leq t < 170$	$170 \leq t < 175$	$175 \leq t < 180$
Effectifs	2	4	7	8	3	3
Fréquences	0,07	0,15	0,26	0,30	0,11	0,11

Chaque fréquence est le quotient de l'effectif de la classe par l'effectif total ; par exemple, pour la première classe : $\frac{2}{27} \approx 0,07$.

L'effectif total est 27.

Histogramme des effectifs des tailles



Remarque :

Dans un histogramme, **l'aire des rectangles est proportionnelle à l'effectif** (ou à la fréquence).

Ainsi, dans l'exemple, en regroupant les deux premières classes, on obtiendrait la représentation ci-dessus à droite : la classe $[150; 160[$ a une largeur double, donc une hauteur deux fois moindre (3 au lieu de 6), de sorte que l'aire reste fidèle à l'effectif (6 élèves).

3) Moyenne pondérée

Classes centrées x_i	152,5	157,5	162,5	167,5	172,5	177,5
Effectifs n_i	2	4	7	8	3	3

Il s'agit d'un calcul de **moyenne pondérée** car des effectifs différents n_i sont associés à chaque valeur x_i .

Définition :

La **moyenne** d'une série statistique dont les valeurs sont $x_1, x_2, \dots, x_k$ et les effectifs correspondants $n_1, n_2, \dots, n_k$ est notée $\bar{x}$ et est égale à :

$$\bar{x} = \frac{n_1x_1 + \dots + n_kx_k}{n_1 + \dots + n_k}.$$

Ainsi dans l'exemple :

$$\begin{aligned}\bar{x} &= (2 \times 152,5 + 4 \times 157,5 + 7 \times 162,5 + 8 \times 167,5 + 3 \times 172,5 + 3 \times 177,5) : 27 \\ &= 4462,5 : 27 \\ &\approx 165,3 \text{ cm.}\end{aligned}$$

4) Linéarité de la moyenne

Propriété :

Si une série de valeurs x_i a pour moyenne $\bar{x}$, alors la série de valeurs $ax_i + b$, avec a et b réels, a pour moyenne $a\bar{x} + b$.

Exemple :

				Moyennes
x_i	4	7	-2	$(4 + 7 - 2) : 3 = 3$
$2x_i - 5$	3	9	-9	$(3 + 9 - 9) : 3 = 1$

On a $\bar{x} = 3$, et donc en appliquant la propriété, la moyenne de la série $2x_i - 5$ est égale à : $2\bar{x} - 5 = 2 \times 3 - 5 = 1$.

On retrouve bien le résultat calculé directement dans le tableau.

5) Variance, écart-type

Définitions :

La **variance** V d'une série statistique de moyenne $\bar{x}$ dont les valeurs du caractère sont $x_1, x_2, x_3, \dots, x_k$ et les effectifs correspondants sont $n_1, n_2, n_3, \dots, n_k$ est égale à :

$$V = \frac{n_1 \times (x_1 - \bar{x})^2 + n_2 \times (x_2 - \bar{x})^2 + \dots + n_k \times (x_k - \bar{x})^2}{n_1 + n_2 + \dots + n_k}.$$

L'**écart-type** σ d'une série statistique de variance V est égal à : $\sigma = \sqrt{V}$.

Ainsi en reprenant l'exemple des tailles de la 2nde 5, la variance est égale à (en utilisant la valeur approchée $\bar{x} \approx 165,3$) :

$$V = \frac{2 \times (152,5 - 165,3)^2 + 4 \times (157,5 - 165,3)^2 + 7 \times (162,5 - 165,3)^2 + 8 \times (167,5 - 165,3)^2 + 3 \times (172,5 - 165,3)^2 + 3 \times (177,5 - 165,3)^2}{27}$$

$$V \approx 46,914 \quad \text{puis} \quad \sigma \approx \sqrt{46,914} \approx 6,85.$$

L'écart-type possède la **même unité** que les valeurs de la série. Ainsi pour la série étudiée, l'écart-type est environ égal à 6,85 cm.

Remarque :

L'écart-type exprime la **dispersion** des valeurs d'une série statistique autour de sa moyenne. Les valeurs extrêmes influencent l'écart-type.

Exercices

Les exercices suivants reprennent, dans l'ordre, les notions de la leçon : caractéristiques d'une série (Partie I), puis cas de pondération (Partie II).

Exercice 1 — Moyenne, médiane, étendue

On a relevé les notes obtenues par 11 élèves à un devoir :

13 7 12 16 9 12 10 15 11 14 13

1. Calculer la moyenne de cette série de notes.
2. Ranger les notes dans l'ordre croissant, puis déterminer la médiane.
3. Calculer l'étendue de la série.
4. Préciser, pour chacune des trois caractéristiques, s'il s'agit d'une caractéristique de *position* ou de *dispersion*.

Exercice 2 — Quartiles et écart interquartile

Voici les âges (en années) des 12 membres d'un club de robotique :

17 15 22 16 18 14 19 16 20 15 18 17

1. Ranger la série dans l'ordre croissant.
2. Déterminer la médiane.
3. Déterminer le premier quartile Q_1 et le troisième quartile Q_3 , en détaillant la position de chaque donnée comme dans la leçon.
4. Calculer l'écart interquartile $E_Q = Q_3 - Q_1$.
5. Compléter : « Au moins 75 % des membres ont au plus ... ans. »

Exercice 3 — Comparer deux séries

Deux joueurs de basket ont marqué, lors de leurs 5 derniers matchs :

Joueur A : 10 ; 12 ; 11 ; 13 ; 14

Joueur B : 2 ; 20 ; 5 ; 18 ; 15

1. Calculer la moyenne de points de chaque joueur. Que remarque-t-on ?
2. Calculer l'étendue de chaque série.
3. Quel joueur est le plus *régulier* ? Justifier à l'aide d'une caractéristique de dispersion.

Exercice 4 — Moyenne pondérée

Le tableau ci-dessous donne le nombre de buts marqués par match par une équipe au cours de 25 matchs.

Buts marqués	0	1	2	3	4
Effectif (matchs)	5	8	7	3	2

1. Vérifier que l'effectif total est bien égal à 25.


2. Calculer le nombre moyen de buts par match (moyenne pondérée), arrondi au centième.
3. Déterminer la médiane de cette série.

Exercice 5 — Regroupement par classe, histogramme

Une enquête sur la durée (en minutes) de 30 communications téléphoniques est résumée dans le tableau suivant.

Durée (min)	[0 ; 10[	[10 ; 20[	[20 ; 30[	[30 ; 40[	[40 ; 50[
Effectif	6	11	9	3	1
Fréquence	...	...	...	...	...

1. Compléter la ligne des fréquences (arrondies au centième). Vérifier que leur somme vaut bien 1.
2. Tracer l'histogramme des effectifs sur le repère ci-dessous.
3. Donner les classes centrées x_i , puis calculer la durée moyenne d'une communication.



Exercice 6 — Linéarité de la moyenne

1. Une série de valeurs x_i a pour moyenne $\bar{x} = 14$. *Sans recalculer*, donner la moyenne de la série de valeurs $0,5x_i + 3$.
2. Les températures relevées une semaine ont pour moyenne 18°C . On les convertit en degrés Fahrenheit à l'aide de la formule $F = 1,8C + 32$. Quelle est la moyenne des températures exprimée en degrés Fahrenheit ?

Exercice 7 — Variance et écart-type

Un magasin a vendu en une journée les pointures de chaussures suivantes.

Pointure x_i	38	39	40	41
Effectif n_i	2	5	2	1

1. Calculer la pointure moyenne $\bar{x}$.
2. Calculer la variance V de la série.
3. En déduire l'écart-type σ , arrondi au centième. Préciser son unité.

Exercice 8 — Médiane d'une série à effectif pair


On a relevé les durées (en minutes) de 12 trajets domicile–lycée :

4 6 7 9 10 11 12 13 14 15 16 19

1. Calculer la moyenne de cette série (arrondie au dixième).
2. L'effectif est *pair* : déterminer la médiane comme moyenne des deux valeurs centrales.
3. Déterminer le premier quartile Q_1 , le troisième quartile Q_3 , puis l'écart interquartile.
4. Interpréter l'écart interquartile par une phrase.

Exercice 9 — Lecture d'un histogramme

On a relevé le temps d'attente (en minutes) de 30 clients à un guichet. Les effectifs sont représentés par l'historgramme ci-dessous.



1. Lire les effectifs et compléter le tableau ci-dessous.

Temps (min)	[0 ; 5[	[5 ; 10[	[10 ; 15[	[15 ; 20[	[20 ; 25[
Effectif	...	...	...	...	...
Fréquence	...	...	...	...	...

2. Calculer les fréquences (arrondies au centième). Vérifier que leur somme vaut 1.
3. Donner les classes centrées, puis calculer le temps d'attente moyen.

Exercice 10 — Synthèse (Parties I et II)

Le tableau donne le nombre d'enfants par famille dans un petit immeuble de 30 familles.

Nombre d'enfants x_i	0	1	2	3	4	5
Effectif n_i	3	6	8	7	4	2

1. Vérifier que l'effectif total est 30, puis calculer le nombre moyen d'enfants par famille.
2. Déterminer la médiane et l'étendue de la série.
3. Déterminer le premier quartile Q_1 , le troisième quartile Q_3 , puis l'écart interquartile.
4. Calculer la variance, puis l'écart-type de la série (on utilisera la valeur approchée de la moyenne).